Matematički fakultet, Univerzitet u Beogradu

Seminarski rad na predmetu Istraživanje podataka 2

Klasifikacija lažnih vesti

Student:
Maša Mitrović, 359/2020
Profesor:
Mirjana Maljković Ružičić

1. Uvod

1.1 Pozadina i motivacija istraživanja

U savremenom digitalnom dobu, internet i društvene mreže su postali glavni način informisanja, prevazišavši televiziju, kao i fizičke novine. Zbog dostupnosti velikih količina informacija na jednom mestu, brzog širenja dezinformacija i lažnih vesti, ovaj način informisanja je postao ozbiljan društveni i politički problem. Motivacija za ovo istraživanje leži u potrebi za automatizovanim sistemom koji može brzo i precizno da razlikuje kredibilne vesti od lažnih, plasiranih sadržaja. Razvojem i poređenjem različitih algoritama, od klasičnih statističkih modela do savremenih dubokih neuronskih mreža, ovo istraživanje teži da identifikuje najefikasniji matematički model za očuvanje integriteta informacija u digitalnom svetu.

1.2 Skup podataka

Korišćen je skup podataka *Fake News Classification* koji sadrži 72134 redova sa četiri atributa. Za potrebe projekta, fokus je stalvjen na tri ključna atributa:

- naslov vesti (title)
- tekst vesti (text)
- labela (label - sadrži samo vrednosti 0 ili 1)

Spoj naslova i teksta vesti se koristi kao ulazni atribut, dok je labela ciljna promenljiva koju model treba da predvidi.

1.3 Istraživački problemi

1. Da li je moguće na osnovu naslova i teksta klasifikovati prave i lažne vesti?
2. Koji algoritam klasifikacije daje najpouzdanije rezultate?
3. Koji parametri su optimalni za različite klasifikacione modele?
4. Da li je moguće primenom nenadgledanog učenja (klasterovanja) prirodno razdvojiti vesti na prave i lažne?
5. Kolika je prediktivna moć samog naslova vesti u poređenju sa celokupnim sadržajem?

1.4 Organizacija rada

Rad je organizovan u pet poglavlja. Poglavlje 2 opisuje pripremu podataka i kreiranje atirbuta. Poglavlje 3 predstavlja primene različitih klasifikacionih modela. Poglavlje 4 prikazuje i upoređuje rezultate naših modela, a 5. poglavlje donosi zaključak.

2. Podaci i priprema

2.1 Izvor i struktura podataka

Skup podataka *Fake News Classification* je preuzet u CSV formatu sa sajta *Kaggle*. Svaki red predstavlja jednu vest. Tabela sadrži 4 kolone: neimenovanu ***Unknown*** kolonu, ***title*** kolonu koja sadrži naslov vesti, ***text*** kolonu koja sadrži tekstualni sadržaj vesti i ***label*** kolonu koja sadrži samo 2 vrednosti - 0 i 1. Vrednosti 0 ili 1 označavaju da li je vest lažna ili prava, odnosno pripadnost našim dvema klasama. Skup podataka je gotovo u potupnosti izbalansiran i sadrži približno 36 hiljada instanci za svaku od dve klase.

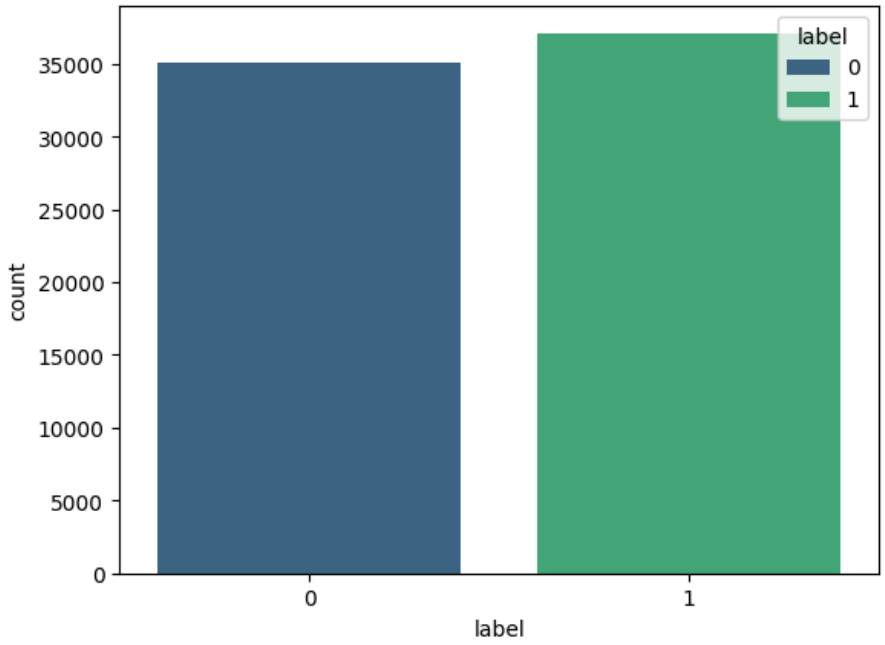

Slika 1: Prikaz izbalansiranog sadržaja vesti

2.2 Pretprocesiranje

Priprema podatka za klasifikaciju i klasterovanje izvršena je kroz nekoliko osnovnih koraka.

2.2.1 Uklanjanje nedostajućih vrednosti

Analizom pomoću `isnull().sum()` dolazi se do informacija da kolona ***title*** ima 558 nedostajućih vrednosti, dok kolona ***text*** ima 39 nedostajućih vrednosti. Redovi nisu

uklonjeni, jer postoje vesti bez naslova ili teksta, već su nedostajuće vrednosti zamenjene praznim karakterom pomoću fillna(“”).

2.2.2 Modifikacija kolona

Prva, neimenovana kolona uklonjena je korišćenjem funkcije drop, s obzirom na to da predstavlja indeks vesti koji nije koristan za klasifikaciju. Kreirana je nova kolona ***content*** koja predstavlja spojene kolone ***title*** i ***text*** sa razmakom između. Na ovaj način dobijen je celovit sadržaj vesti koji ćemo koristiti u daljoj analizi.

2.2.3 Čišćenje teksta

Tekstualni sadržaj jedne vesti, odnosno tekstualni sadržaj atributa ***content*** je prosečne dužine 3345 karaktera, dok najduži redovi dostižu i do 143035 karaktera. Takvi tekstualni podaci sadrže dosta elemenata koji ne doprinose semantičkoj vrednosti rečenice, već povećavaju dimenzionalnost prostora i unose šum, zbog čega je primenjen proces čišćenja kroz funkciju clean_text. Prvi korak čišćenja jeste normalizacija teksta, odnosno prebacivanje velikih slova u mala, čime se izbegava da model reči "Vest" i "vest" tretira kao različite entitete. Zatim je izvršeno uklanjanje interpunkcije i brojeva pomoću regularnih izraza, jer ovi simboli obično nemaju značaj za samu detekciju istinitosti teksta. Osim toga, uklanjaju se ***stop-words***, odnosno česte reči u engleskom jeziku, koje se pojavljuju u gotovo svakom tekstu i nisu značajne za klasifikaciju. Skup tih reči preuzet je iz paketa nltk.corpus. Finalni rezultat ovog procesa je pročišćen niz reči koji zadržava samo ključne informacije iz vesti, što direktno doprinosi stabilnosti i preciznosti svih narednih modela klasifikacije.

2.2.4 Trening i test skup

Skup vesti podelili smo na trening i validacioni skup korišćenjem funkcije train_test_split, gde je naš ulazni atribut *X* očišćeni tekstualni sadržaj iz kolone ***clean_content***, a ciljna promenljiva *y* predstavlja sadržaj kolone ***label***. Odnos trening i test skupova je 80:20 procenata celog skupa.

2.2.5 TF-IDF vektorizacija

Za transformaciju tekstualnih podataka u numerički format pogodan za algoritme mašinskog učenja korišćena je tehnika **TF-IDF** (Term Frequency - Inverse Document Frequency), koja predstavlja napredniji pristup od običnog brojenja reči. Ova statistička mera se koristi da odredi koliko je neka reč važna za određenu vest u okviru celog korpusa vesti. Umesto da samo broji reči, dodeljuje im se težina koja predstavlja proizvod TF x IDF, gde je:

- **TF** (Term Frequency) - *koliko je reč česta u ovoj vesti?*

- **IDF** (Inverse Document Frequency) - *koliko je reč retka u svim vestima?*

Ukoliko se neka reč pojavljuje u većini vesti, ona nam neće pomoći da razlikujemo prave i lažne vesti, pa će njena IDF biti mala, a samim tim i ceo proizvod. Pomoću TfidfVectorizer kreirana je matrica atributa gde kolone predstavljaju jedinstvene reči (n-grami), a vrednosti u poljima njihovu statističku važnost za svaku pojedinačnu vest. Prilikom vektorizacije, ignorisali smo reči koje se pojavljuju u 90% vesti, kao i one koje se pojavljuju manje od 5 puta, čime smo značajno smanjili dimenzionalnost prostora. Konačne dimenzije našeg trening skupa su 57707 x 57163, dok je 14427 x 57163 dimenzija test skupa.

Slika 2: Histogram vesti po dužini njihovog sadržaja

3. Metode

3.1. Radni tok: pregled

Kompletan radni tok sastoji se od sledećih koraka:

1. Učitavanje podataka i inicijalna analiza
2. Pretprocesiranje podataka
3. Podela skupa na trening i validacioni skup
4. Podešavanje hiperparametara modela - GridSearchCV
5. Treniranje 6 klasifikacionih modela i 1 modela klasterovanja
6. Treniranje klasifikacionih modela nad naslovima vesti kao ulaznim atributom
7. Poređenje rezultata
8. Donošenje finalnog zaključka

3.3. Algoritmi klasifikacije

3.3.1. Multinomial Naive Bayes (NB)

Multinomial Naive Bayes jeste algoritam za klasifikaciju zasnovan na Bajesovoj teoremi. On prvo za svaku reč izračuna verovatnoću da se pojavi u lažnoj vesti, kao i verovatnoću da se pojavi u pravoj vesti. Multinomial (učestalost) podrazumeva da model ne gelda samo da li se reč pojavljuje ili ne, već koliko puta se pojavljuje. Iako je naivan, odnosno pretpostavlja da su reči nezavisne jedne od druge, njegova visoka preciznost pokazuje da su određene ključne reči same po sebi toliko snažni indikatori lažnih vesti da je čak i jednostavna statistička verovatnoća dovoljna za zadovoljavajuću preciznost.

3.3.2. Logistička regresija

Logistička regresija jeste linearni model, koji radi slično kao obična linearna regresija - pokušava da pronađe težine za svaku reč iz TF-IDF matrice. Te vrednosti propušta kroz sigmoidnu funkciju koja vraća broj u rasponu od 0 do 1. Model postavlja neku granicu odluke (obično 0.5) pomoću koje klasifikuje vesti kao prave ili lažne. Kako je tačnost ovog modela prilično visoka, to pokazuje da je granica između lažnih i pravih vesti u vektorskom prostoru reči prilično jasna i linearno razdvojiva.

3.3.3. LinearSVC

LinearSVC (Linear Support Vector Classification) je još jedan linearni model, koji za razliku od logističke regresije ne računa verovatnoću, već pokušava da postavi hiperravan tako da maksimalno razdovji klase. Ako su naše prave i lažne vesti tačke u prostoru, on neće povući samo bilo koju liniju između njih nego traži onu liniju koja ostavlja najveći mogući prazan prostor. Veoma je efikasan u visokodimenzionim prostorima.

3.3.4. Passive Aggressive

Passive-Aggressive (PA) algoritam spada u specifičnu porodicu algoritama za online učenje. Kada model dobije novi podatak i ispravno ga klasifikuje sa dovoljnom sigurnošću, on ne radi ništa, pasivan je. Kada model napravi grešku, on postaje agresivan i odmah menja svoje težine. Na taj način se brzo prilagodi specifičnom rečniku dezinformacija, uz minimalne promene.

3.3.5. LGBM

LGBM (Light Gradient Boosting Machine) pripada porodici Boosting modela, što znači da

ne pravi jedno ogromno stablo odlučivanja, već gradi seriju malih, slabih stabala gde svako sledeće ispravlja greške prethodnog. Naziv “light” je dobio zato što za razliku od *level-wise* modela, on je *leaf-wise* što znači da bira samo list koji donosi najveće smanjenje greške i razvija ga u dubinu. Brz je jer ne troši vreme na vesti koje već savršeno klasifikuje već na one gde pravi velike greške. Dok *LinearSVC* povlači jednu liniju, *LGBM* pravi stotine “stepenica” što mu omogućava da reši mnogo komplikovanije probleme.

3.3.7. LSTM

LSTM (Long Short-Term Memory) pripada porodici rekurentnih neuronskih mreža koje imaju sposobnost da pamte informacije na duge staze. Za razliku od prethodnih modela, *LSTM* ne posmatra samo učestalost reči, već i njihov redosled i kontekst. Zbog prirode modela korišćen je drugačije pripremljen ulazni skup vesti gde nisu izbačene najčešće reči engleskog jezika iz skupa stopwords. Ne koristi se TF-IDF vektor, jer on poništava redosled reči, već umesto njega koristimo Embedding sloj.

3.3.8. K-Means

Pored klasifikacije, sprovedeno je i klasterovanje korišćenjem K-means modela koji za cilj ima particionisanje skupa u k klastera. Broj klastera u našem slučaju postavljamo na dva i svaka vest će pripasti onom klasteru gde se nalaze njoj najsličnije vesti. On ne zna da grupiše vesti u prave i lažne, već ih grupiše po temama.

3.2. Podešavanje parametara - GridSearch

Za NB, LR, LSVC i PA modele primenjena je pretraga mreže (GridSearchCV) u cilju pronalaska optimalnih parametara za klasifikaciju našeg skupa vesti.
Kod Naivnog Bajesa tražili smo optimalni faktor poravnanja alfa koji sprečava da model dodeli verovatnoću 0 rečima koje se nisu pojavile u trening skupu. Testiran je raspon vrednosti od 0.01 do 10, a dobijena vrednost od 0.01 ukazuje na to da model postiže najbolje performanse kada se oslanja na bogatstvo rečnika uz minimalno statističko poravnanje.
U slučaju Logističke regresije tražili smo optimalni parametar regularizacije C koji kontroliše koliko ćemo kazniti model za prevelike težine reči. Veće C dozvoljava modelu da se više prilagodi trening podacima, dok manje C sprečava da dođe do preprilagođavanja, pa dobijena vrednost 10 ukazuje na veći kapacitet prilagođavanja specifičnostima trening skupa. LinearSVC model pored parametra C ima i parametar dual koji bira matematički algoritam za rešavanje problema (primarni ili dualni), a najbolji rezultat daju vrednosti C=1 i dual=True.
Passive-Agressive model ima parametre C i max_iter. Parametar C određuje njegovu agresivnost - koliku će promenu model napraviti kada pogreši, a max_iter predstavlja broj epoha - maksimalan broj prolazaka kroz ceo set podataka. Dobijena vrednost C=0.1

pokazuje da model ne treba biti previše agresivan i da je dovoljno proći 50 puta kroz ceo set podataka.

3.4. Metrike evaluacije

Osnovna metrika korišćena na modelima jeste ***Tačnost (Accuracy)***. Ona izračunava procenat tačnih predviđanja u odnosu na ukupan broj vesti. Pošto je skup podataka izbalansiran, odnosno imamo približno sličan broj pravih i lažnih vesti u skupu, tačnost je odličan pokazatelj kvaliteta modela. Osim toga, za svaki model prikazan je *Classification Report*, gde smo analizirali preciznost i odziv. Preciznost računa od svih vesti za koje model predvidi da su lažne, koliko je zaista lažno, dok odziv računa od svih stvarno lažnih vesti, koliko je model uspeo da detektuje.

3.3. Klasifikacija na osnovu naslova

Sproveden je dodatni eksperiment u okviru ovog istraživanja sa ciljem da se utvrdi koliko je prediktivan naslov u poređenju sa celokupnim tekstualnim sadržajem. Za razliku od obrade celog teksta, u tekstu naslova su zadržane reči iz skupa stop-words, budući da su naslovi kratki i one mogu biti od ključnog značaja. Velika slova su pretvorena u mala i izbačeni su znakovi interpunkcije. Prilikom ovog eksperimenta trenirali smo 4 različita modela - *Multinomial Naive Bayes*, *Logistic Regression*, *LinearSVC* i *Passive-Agressive*.

4. Rezultati i vizualizacija

Nakon sprovedenog testiranja, najbolje rezultate pokazala je grupa modela zasnovana na gradijentnom boostingu i linearnoj klasifikaciji. **LGBM** se izdvojio kao najprecizniji model sa tačnošću od **96,91%**, što potvrđuje njegovu superiornost u pronalaženju složenih interakcija između termina unutar TF-IDF matrice. Neposredno iza njega, sa minimalnim razlikama, pozicionirali su se **LinearSVC**, **Passive-Aggressive Classifier** i **Logistička regresija**. Ovako visoka i ujednačena preciznost linearnih modela sugeriše da su rečnik i stil pisanja u bazi vesti veoma jasno definisani, omogućavajući matematički precizno razdvajanje klasa.
S druge strane, **LSTM** mreža je postigla visoku, ali nešto nižu od vodećih modela - **94%**. Iako ovaj model uzima u obzir sekvencijalni redosled reči, činjenica da ima lošije rezultate od prethodnih modela nam govori da je u ovom konkretnom problemu prisustvo ključnih diskriminativnih reči, koje hvata TF-IDF, značajniji faktor od same strukture rečenica.
Značajniji pad performansi primećen je kod **Multinomial Naive Bayes**, čija pretpostavka o nezavisnosti reči očigledno nije bila dovoljna da parira složenijim algoritmima. Na samom začelju nalazi se **K-Means** sa svega **53%** tačnosti, što je očekivano za nenadgledano učenje. Ovaj rezultat služi kao ključni dokaz da bez prethodnog

poznavanja labela, algoritmi zasnovani isključivo na sličnosti sadržaja ne mogu efikasno identifikovati dezinformacije, jer one lingvistički teže da imitiraju strukturu pravih vesti.

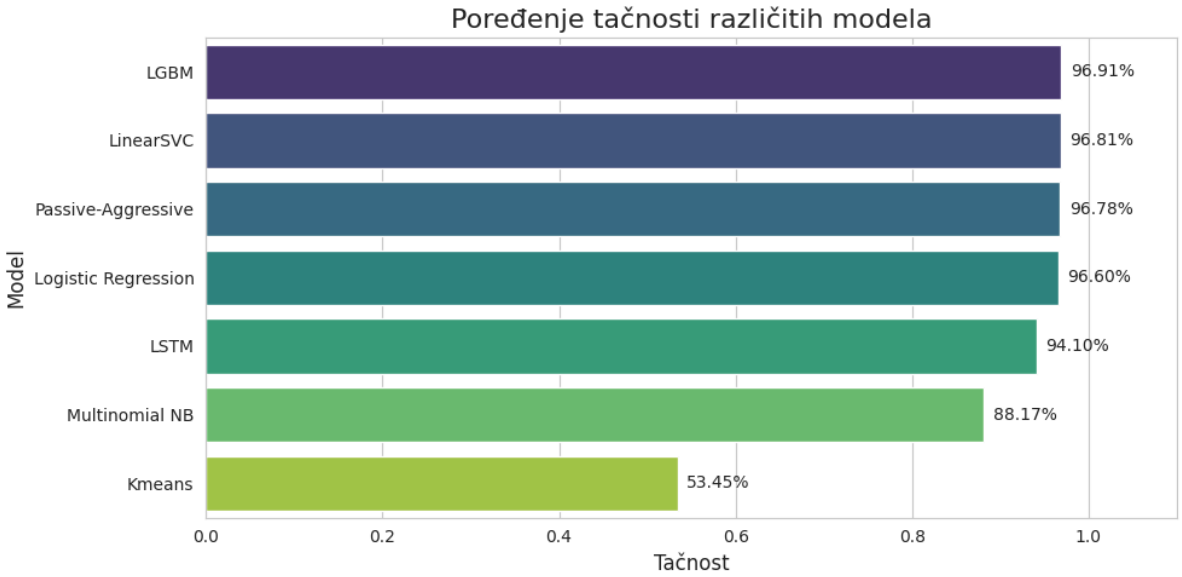

Slika 3: Vizualni prikaz poređenja tačnosti modela

4.1. Učestale reči u vestima

Korišćenjem wordcloud paketa prikazane su reči iz TF-IDF matrice koje se najviše pominju u vestima. Može se primetiti da je najčešća tema i u pravim i u lažnim vestima politika u SAD. One se ne razlikuju po sadržaju i zato je teško razdvojiti prave od lažnih putem nenadgledanog učenja.

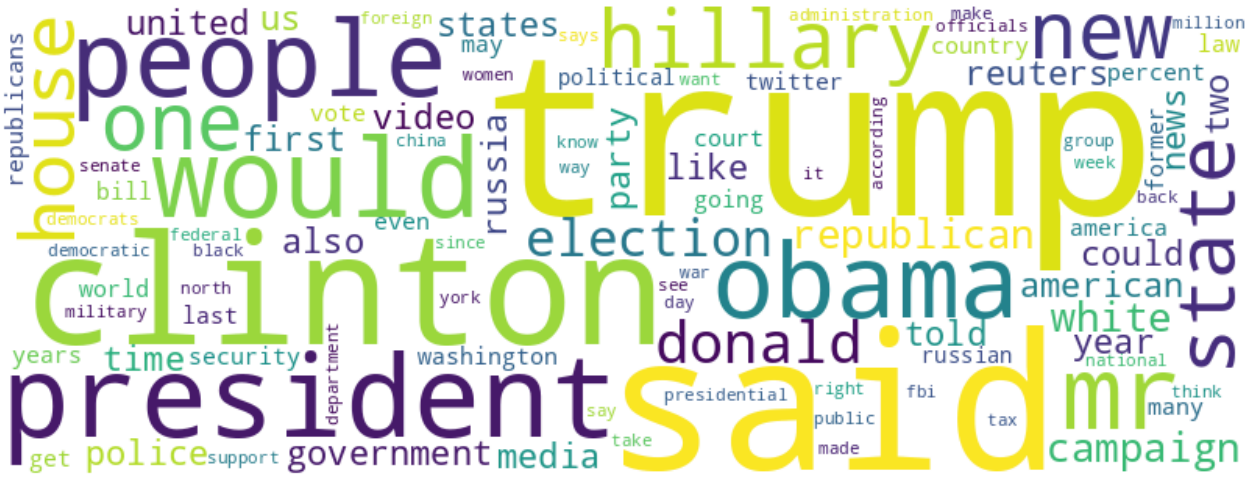

4.2. Rezultati klasifikacije modela obučenih na naslovima

U tabeli ispod prikazano je poređenje tačnosti (Accuracy) modela obučenih na celom tekstu u odnosu na one obučene isključivo na naslovima vesti:

Model	Tačnost (ceo tekst)	Tačnost (naslov)	Razlika (%)
Multinomial NB	0.881680	0.869368	1.231239
Logistička Regresija	0.966036	0.913587	5.244879
LinearSVC	0.968115	0.915124	5.299134
Passive-Aggressive	0.967838	0.909466	5.837249

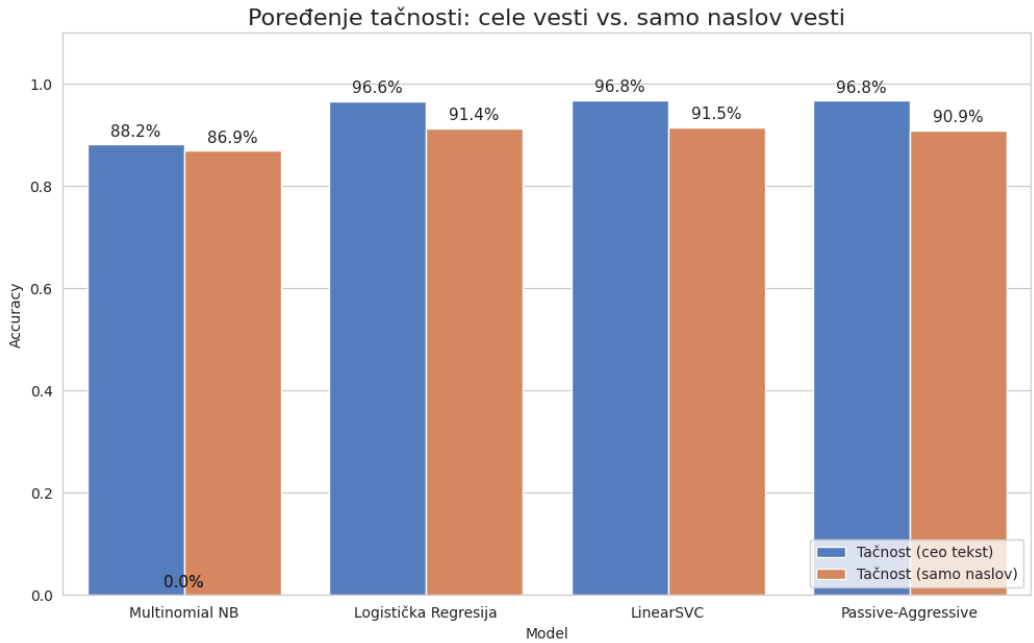

Slika 4: Poređenje tačnosti s različtim ulaznim atributima

5. Zaključak

Cilj ovog istraživanja bio je razvoj i evaluacija različitih modela za detekciju lažnih vesti. Analizom skupa podataka od preko 70 hiljada vesti, testirani su različiti pristupi, od klasičnih statističkih metoda do savremenih neuronskih mreža. Na osnovu dobijenih tačnosti, vremena učenja i predviđanja modela, možemo zaključiti da su linearni modeli najoptimalniji za klasifikaciju lažnih vesti u našem skupu. Primarni razlog leži u visokoj dimenzionalnosti i linearnoj razdvojivosti. Kako TF-IDF vektorizacija stvara prostor sa hiljadama dimenzija, prave i lažne vesti se često grupišu tako da je moguće povući hiperravan koja ih razdvaja. Linearni modeli su matematički optimizovani upravo za pronalaženje te granice. Kod detekcije lažnih vesti, prisustvo određenih reči često je jači signal od samog redosleda reči u rečenici. Linearni modeli dodeljuju težinu svakoj reči nezavisno, što im omogućava da veoma brzo identifikuju koji termini najviše ukazuju na lažni sadržaj. Poseban doprinos rada je poređenje klasifikacije na osnovu naslova i celog teksta. Rezultat od preko 90% tačnosti potvrđuje da u naslovima pravih i lažnih vesti postoje ključne razlike, ali i opravdava potrebu za analizom celog teksta radi postizanja maksimalne tačnosti.